

모터 전류 신호를 이용한 전동차 출입문 고장진단 연구

Fault Diagnosis Study of Train Door Using Motor Current Signal

저자 (Authors)	함석주, 한석윤, 김석구, 박형준, 박기준, 최주호 Seokju Ham, Seok-Youn Han, Seokgoo Kim, Hyung Jun Park, Kee-Jun Park, Joo-Ho Choi
출처 (Source)	신뢰성응용연구 19(4) , 2019.12, 353-361(9 pages) Journal of Applied Reliability 19(4) , 2019.12, 353-361(9 pages)
발행처 (Publisher)	한국신뢰성학회 The Korean Reliability Society
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09284152
APA Style	함석주, 한석윤, 김석구, 박형준, 박기준, 최주호 (2019). 모터 전류 신호를 이용한 전동차 출입문 고장진단 연구. 신뢰성응용연구 , 19(4), 353-361
이용정보 (Accessed)	한국항공대학교 203.253.***.19 2020/05/18 15:17 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

모터 전류 신호를 이용한 전동차 출입문 고장진단 연구*

함석주¹ · 한석윤² · 김석구¹ · 박형준¹ · 박기준² · 최주호^{3†}

¹한국항공대학교 항공우주 및 기계공학과, ²한국철도기술연구원 도시철도연구팀

³한국항공대학교 항공우주 및 기계공학부

Fault Diagnosis Study of Train Door Using Motor Current Signal*

Seokju Ham¹ · Seok-Youn Han² · Seokgoo Kim¹ · Hyung Jun Park¹ · Kee-Jun Park² · Joo-Ho Choi^{1†}

¹Depts of Aerospace and Mechanical Engineering, Korea Aerospace University

²Urban Transit Research Group, Korea Railroad Research Institute

³School of Aerospace and Mechanical Engineering, Korea Aerospace University

Purpose: Passenger train door systems can undergo failure during operation, causing inconveniences such as service delays, breakdowns or even resulting in the human casualties. This study proposes a diagnostic process to predict such failure conditions so they can be avoided in advance.

Methods: A door test rig is prepared, in which the motor signals are acquired for different fault modes during the operation test. Various time domain features are extracted and selected using the Fisher Discriminant Ratio and Pearson correlation. Classifications are then performed by the k-Nearest Neighbor (k-NN) method for the door-open and door-close operations, respectively.

Results: Overall, the fault modes are identified quite well except for the artificial bearing wear. The result is worse in the door-close operation because the high peak current applied near the end to ensure the door closing may have affected the classification accuracy.

Conclusion: The proposed fault diagnosis method is easy to implement for the passenger train door system. Once the diagnosis system is trained via the seeded fault modes, it can be applied with accuracy to the fault diagnostics of train door systems, and be used for the efficient maintenance.

Keywords: Train Door Diagnosis, Motor Current, Feature Extraction, Fisher Discriminant Ratio, k-Nearest Neighbor, k-NN

1. 서론

전철에서 전동차 출입문은 정차역에서 승객이 원활

히 승하차하도록 안전하고 정확하게 작동되어야 하는 중요한 장치로서, 개폐 관련 고장이 발생하면 현장 대응으로 인한 서비스 지연이나 운행중단으로 인한 차량

* 본 논문은 한국철도기술연구원 주요사업의 연구비 지원 및 2018년도 한국항공대학교 교비지원 연구비에 의하여 지원된 연구의 결과입니다.

† 교신저자 jhchoi@kau.ac.kr

2019년 9월 3일 접수; 2019년 10월 3일 수정본 접수; 2019년 10월 24일 게재 확정.

기지 회송 등으로 승객들의 불편이 초래되는 것은 물론, 인명사고의 가능성도 존재한다[1-2]. 해외 철도 운영사인 Bombardier에 따르면 운용 중인 열차의 고장 중 30~40%가 출입문에 의한 고장이라고 하였다[3-4]. 이러한 고장을 예방하기 위해 최근 건전성 예측관리(Prognostics and Health Management, PHM) 연구가 활발히 전개되고 있으며, 이를 통하여 상태에 기반한 유지보수(Condition Based Maintenance, CBM)를 실천하고자 하고 있다. 그러나 이러한 연구를 전동차 출입문에 적용한 사례는 아직 미미하다. 건전성 예측관리는 상태 모니터링, 고장진단 및 고장예지의 단계로 구성되며, 이 중에서 고장진단은 현재 상태의 건전성을 진단하여, 고장종류와 심각도를 추정하는 것이다. 고장진단에는 시스템을 수학적으로 모델링하여 이를 이용하는 모델 기반 방법과 온전히 모니터링되는 데이터만을 이용하여 진단을 수행하는 데이터 기반 방법이 있다. 전동차 출입문의 모델기반 방법에 대해서는 출입문 시스템을 간단한 볼 스크류 시스템으로 모델링하거나[5] 시스템을 에너지 흐름 관점에서 모델링을 하는 본드 그래프 방법[6] 등이 있었다. 하지만 모델기반 방법은 많은 부품들이 복잡하게 결합되어 있는 출입문 시스템의 특성상 이를 정확하게 모델링하는 것이 불가능하기 때문에 한계를 지니고 있다.

데이터 기반 방법은 이러한 한계를 극복하기 위해 정상과 결함 시의 센서신호를 분석하여 고장진단에 활용하는 것이며, 그러나 이를 출입문 시스템에 적용한 사례 또한 매우 드물다. Sun *et al.*[7]은 음향센서를 이용하여 Empirical Mode Decomposition(EMD)과 Support Vector Machine(SVM)기법을 적용, 특징추출 및 결합분류를 수행하였다. 한편 출입문과 유사한 왕복 메커니즘 설비에 대한 고장진단 연구도 있었는데, 엘리베이터 문에 대해 Yan and Lee는 작동 중 측정되는 모터 전류, 엔코더, 4개의 스위치 신호와 별도로 부착한 진동 센서 신호를 이용하여 Wavelet Packet Decomposition(WPT)과 logistic regression을 적용한 고장진단을 수행하였다[8]. 선로 전환기의 경우, Alessi *et al.*[9]는 작동기 모터 전류에 대해 Self-Organizing Map(SOM)을 적용하여 다양한 고장 모드에 대한 진단연구를 했으며, Lee *et al.*[10]은 음향 신호로부터 Mel-Frequency Cepstrum Coefficient(MFCC)를 추출하고 이에 대해 Correlation-based Feature Selection(CFS)을 수행하여 특징신호 개수를 줄이고 SVM을 적용하여 고장 진단을 수행하였다.

이러한 선행 연구들을 살펴보면 대부분 고장 진단을 위해 음향 또는 진동 센서를 추가로 이용하여 데이터를 확보했음을 알 수 있다. 그러나 출입문에 이러한 센서를 추가하는 것은 비용과 시스템 복잡도 증가 면에서 현실적으로 적용하기 어렵다. 따라서 본 연구에서는 출입문에 추가 센서 없이 출입문 작동을 위해 사용되는 모터의 전류와 엔코더 신호를 활용한 고장진단 방법을 연구하였다. 모든 고장 모드를 실험할 수 없기 때문에 본 연구에서는 출입문 운영사 및 제작사의 의견을 반영하여 고장 모드를 정의하였고 제작사의 테스트베드를 통해 실험을 진행하였다. 고장진단은 세단계로 구성되며, 첫째 획득된 전류 데이터로부터 시간기반 특징신호를 추출한 후, 둘째 Fisher discriminant ratio(FDR)와 Pearson 상관계수를 이용하여 분류에 적합한 특징신호들을 찾으며, 셋째 k-nearest neighbor(KNN) 알고리즘을 적용하여 각종 고장 모드들을 분류하는 것이다. 이렇게 분류된 결과는 혼동행렬을 통해 정확도를 확인하였다.

2. 데이터 계측

본 연구는 <Fig. 1>과 같은 전동차의 전기식 출입문 시스템을 대상으로 하고 있으며, 이는 door control unit(DCU), 모터, 엔코더, 캠팔로워 베어링, 롤러, 스핀들 등으로 이루어져 있다. 출입문의 작동은 모터를 통해 이뤄지며 DCU에서 엔코더를 통해 모터전류를 제어한다. 이때 엔코더는 모터의 회전각도를 측정하여 출입문이 사전에 주어진 속도 프로파일을 따라 움직이도록 모터 전류를 제어하는데 활용한다. 출입문은 모터가 스핀들을 회전하면 스핀들 스크류를 따라 너트 어셈블리가 직선운동을 하며, 여기에 도어패널이 체결되어 있는 행거 어셈블리가 포크로 연결되어 함께 이동하는 방식으로 구성되어 있다. 이때 캠팔로워 베어링은 베이스 프레임의 트랙 내에서 이동하면서 너트 어셈블리가 회전하지 않도록 하며, 동작 중 소음을 최소화하기 위해 우레탄을 입혀 제작된다. 행거 어셈블리에 부착된 롤러는 베어링과 마찬가지로 우레탄을 입혀 제작되었으며 하나로 체결된 너트, 행거 어셈블리 및 도어 패널 일체가 이동할 때 롤러 트랙 위에서 도어패널 자중을 지탱하면서 구름 회전을 한다. 시험에 이용된 테스트베드는 출입문 제작사의 것을 사용했으며




Fig. 1 Composition of train door system



Fig. 2 Train door test-rig




Fig. 3 Motor current and encoder signal

이는 <Fig. 2>와 같다. 전류와 엔코더 신호는 DCU에 케이블을 연결하여 도어 작동 중 획득할 수 있으며 대표적 형태가 <Fig. 3>과 같다. <Fig. 3>에서 보면 열림과 닫힘에 대해서 전류 신호의 파형이 다를 수 있고 마찬가지로 엔코더 신호도 차이가 나는 것을 확인할 수 있다. 닫힘 작동 구간이 끝나는 지점에 전류가 튀는 현상을 확인할 수 있는데 이는 닫힘 동작을 마무리할 때 도어를 확실하게 닫기 위해 모터의 토크를 강하게 걸기 때문에 발생하는 것이다. 참고로 전류신호는 출입문과 유사하게 왕복 메커니즘을 가지는 엘리베이터 도어

Table 1 Experiment data

Class ID	Failure modes	Number of data
1	Normal	82
2	Twisted spindle	46
3	Extreme conditions Twisted spindle & Inclined testbed	88
4	Foreign element insertion	66
5	Natural wear Bearing & Roller	46
6	Artificial wear Bearing	170
7	Artificial wear Roller	68
8	Artificial wear Bearing & Roller	60

[8], 철도 선로 전환기[9], 출입문 시스템[11]에서의 고장 진단에서도 사용된 바 있다.

본 연구에서는 <Table 1>과 같이 정상과 고장조건을 포함한 총 8가지 클래스의 상태 데이터를 선정하였으며 이들에 대한 설명은 다음과 같다. 출입문은 다양한 가혹조건에서 작동되며 이 경우에도 신호 변화가 발생하기 때문에 이들은 실제 고장과는 분리하여 식별해야 한다. 본 연구에서는 3가지 가혹 상황을 시험하였는데 이는 스프링들의 뒤틀림(<Table 1>의 ID2), 여기에 출입문 기울임 추가(ID3) 및 하부 이물질 끼임(ID4)이다. 스프링 뒤틀림은 승객 밀침을 모사하는 것으로 스프링 양끝 단의 결합부에 얇은 철판을 하나씩 끼워 스프링들이 수평을 이루지 않도록 하였다. 출입문 기울임은 경사로에서 작동되는 것을 모사하는 것으로 시험기 전체를 진행방향으로부터 약 6도 정도 기울였다. 하부 이물질 끼임은 하부 가이드레일과 도어 사이에 이물질이 끼었을 때를 모사한 것으로 얇은 철판을 끼워 넣어 마찰이 발생하도록 하였다. 한편 제작사에서는 출입문 수명시험을 위해 내구성 테스트를 수행하였는데, 이 결과로 여러 부품이 자연 마모되었으며,




Fig. 4 Artificial wear in bearing and roller

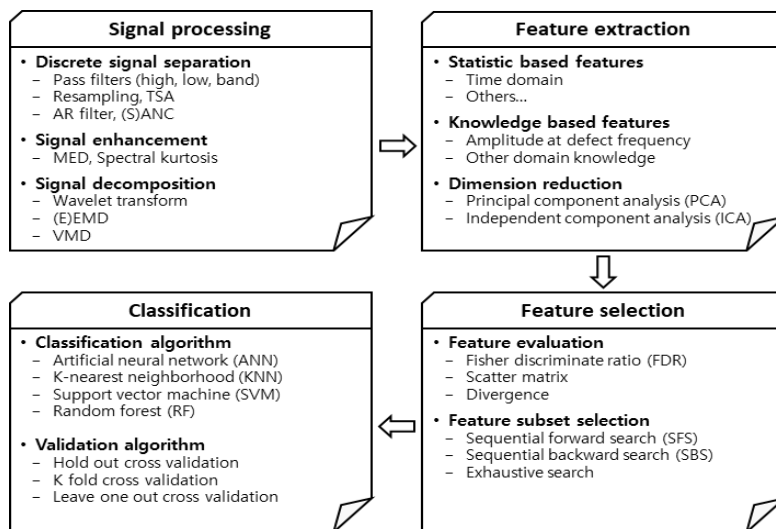


Fig. 5 Typical diagnosis procedure

본 연구에서는 이 중 캠팔로워 베어링과 롤러 두 개의 마모 부품을 선택하여 시험을 하였다(ID5).

또한 자연 마모품의 결합정도가 미흡할 것에 대비, 이와는 별도로 두 부품에 대해서는 <Fig. 4>와 같이 인위적 마모를 인가하여 시험을 하였다. <Fig. 4(a)>는 캠팔로워 베어링의 우레탄 부분에 마모를 가한 것으로 출입문의 양 도어에 하나씩 장착되는 베어링에 대해 하나는 외경을 깎고 다른 하나는 삼각형 형태로 깎았다(ID6). 롤러에 대해서는 운영사의 조인을 토대로 <Fig. 4(b)>와 같이 우레탄 외경이 아닌 금속축에 마모를 인가하였고 그 결과 도어 작동 중 롤러가 흔들리도록 하였다(ID7). 아울러 베어링과 롤러 고장을 함께 인가하기도 하였다(ID8). 이렇게 하여 총 8가지의 조건(고장모드)에 대해 각각 시험을 수행, 도어 작동 중 데이터를 수집하였고 그 결과 획득한 데이터 수는 <Table 1>과 같다.

3. 특징신호 추출 기반 고장진단

일반적으로 고장진단의 절차는 <Fig. 5>와 같이 신호처리(signal processing), 특징추출(feature extraction), 특징선택(feature selection) 그리고 분류(classification)의 4단계를 거친다. 신호처리 단계는 계측된 데이터에서 노이즈를 제거하거나 결합신호가 더 잘 나타나도록 신호를 강조하거나 분리하는 것인데, 본 연구에서는 이런 절차의 필요성이 높지 않아 생략하였다. 특징추출 단계는 원신호를 그대로 진단에 활용하면 데이터 양이 많아 진단이 어렵기 때문에 결합특성이 반영된 다양한 통계적 인자를 추출하는 과정이다. 그러나 이렇게 추출된 특징신호들을 그대로 이용할 경우 여전히 많은 계산량이 발생하며 특히 과적합(over-fitting)으로 인해 분류성능이 떨어지는 문제가 있다. 특징선택 단계는 이를 해결하기 위해 추출된 특징신호 중에 분류에 적합한

인자들을 추리는 과정을 말한다. 마지막으로 고장분류 단계는 이렇게 선택한 특징신호를 가지고 8가지의 고장모드 또는 클래스 데이터를 이용하여 기계학습을 수행한 후, 새로운 모터 데이터가 들어오면 그것이 어느 고장모드에 해당하는지를 식별해 내는 과정이다.

앞서 언급했던 것처럼 출입문은 왕복운동을 하는 시스템이기 때문에 이로부터 획득한 전류신호는 열림과 닫힘 시 신호 파형이 상이하다. 따라서 열림과 닫힘의 조건 별로 신호를 분석할 필요가 있으며 이를 위해 엔코더 신호를 사용하였다. <Fig. 3>에서 엔코더 신호를 보면 도어가 작동 시작과 종료 때 그 값이 상수 구간에서 변화하는 구간으로 또는 그 반대로 바뀌는데 이 시점들을 파란색 점으로 표시하였으며 이동시간평균을 통해 기울기를 계측하여 열림과 닫힘 시의 구간을 식별하였다.

3.1 특징추출

특징신호를 추출하기 위해 열림과 닫힘 구간 별로 모터전류 데이터를 활용하였으며, 각 구간 데이터에 대해 고장진단에서 대표적으로 사용하는 총 13개의 시간영역 통계인자를 구하였고 이는 <Table 2>와 같다. 여기서 x_i 는 i 번째 시간의 전류크기를, N 은 해당 구간에서의 데이터 수를 나타낸다.

3.2 특징선택

특징선택은 추출한 특징신호 중에 고장모드를 보다 잘 식별하는 것을 추려내는 것으로, 이때 특징신호 사이에 높은 상관관계가 있는 경우에는 이들을 되도록 제외하고 독립적인 인자만을 추리는 것이 바람직하다. 본 연구에서는 이를 위해 FDR과 Pearson 상관계수를 이용하였으며 그 과정은 다음과 같다. 우선, 모든 데이터를 training과 test용으로 나눈 후 test 데이터는 알고리즘 검증용으로 남겨 두고 training 데이터를 가지고 진행한다. 앞에서 언급한 특징신호는 크기가 다양하기 때문에 이로 인한 차이를 없애기 위해 특징신호 마다 평균과 표준편차를 이용하여 정규화한다. 이렇게 정규화한 데이터를 가지고 하나의 특징신호가 두 클래스를 얼마나 잘 분류하는지 평가하는 척도인 FDR을 이용하여 가장 우수한 특징신호를 선정한다[12]. 이를 식으로 표시하면 다음과 같다.

Table 2 Extracted time domain features

Feature ID	Feature Name	Equation
1	Mean	$\frac{\sum x_i}{N}$
2	Root amplitude	$\left(\frac{\sum \sqrt{ x_i }}{n}\right)^2 \left(\frac{\sum \sqrt{ x_i }}{N}\right)^2$
3	RMS	$\sqrt{\frac{\sum x_i^2}{N}}$
4	Standard deviation	$\sqrt{\frac{\sum (x_i - \bar{x})^2}{N-1}}$
5	Peak	$\max(x)$
6	Skewness	$\frac{\sum (x_i - \bar{x})^3}{(N-1) \left(\sqrt{\frac{\sum (x_i - \bar{x})^2}{N-1}} \right)^3}$
7	Kurtosis	$\frac{\frac{1}{N} \sum (x_i - \bar{x})^4}{\left(\frac{1}{N} \sum (x_i - \bar{x})^2 \right)^2}$
8	Crest factor	$\frac{ x_{peak} }{x_{rms}}$
9	Clearance factor	$\frac{x_{peak}}{\left(\frac{\sum \sqrt{ x_i }}{N} \right)^2}$
10	Shape factor	$\frac{x_{rms}}{\frac{1}{N} \sum x_i }$
11	Impulse factor	$\frac{x_{peak}}{\frac{1}{N} \sum x_i }$
12	Peak-to-peak	$\max(x) - \min(x)$
13	Root sum of square	$\sqrt{\sum x_i^2}$

$$i_1 = \arg \max_i FDR_i \quad (1)$$

$$\text{where } FDR_i(m, n) = \frac{(\mu_m - \mu_n)^2}{\sigma_m^2 + \sigma_n^2}$$

여기서 FDR_i 는 특징신호 i 에 대한 것으로 8개의 고장모드 중 임의의 두 클래스 m 과 n 에 대해 적용한 FDR 값을, μ 와 σ^2 는 해당 클래스 m 과 n 의 평균과 분산을, i_1 은 총 13개의 특징신호 중 FDR이 가장 높은 것의 인덱스를 나타낸다. 다음에는 이렇게 선정된 특징신호를 기준으로 나머지 특징신호와 Pearson 상관관계를 구한 후 이것과 해당 특징신호의 FDR에 대해 가중치를 적용하여 그 값이 가장 큰 것을 선정한다. 이는 다음 식과 같이 표현된다.

$$i_2 = \arg \max_j \{ \alpha \text{FDR}_j - (1 - \alpha) |\rho_{i_1, j}| \}, \quad (2)$$

for all $j \neq i_1$

$$\rho_{i_1, j} = \frac{\sum_{k=1}^N x_{m,k} x_{n,k}}{\sqrt{\sum_{k=1}^N x_{m,k}^2 \sum_{k=1}^N x_{n,k}^2}} \quad (3)$$

여기서 j 는 i_1 을 제외한 나머지 특징신호이고, $\rho_{i_1, j}$ 는 특징신호 i_1 과 j 사이의 Pearson 상관계수로 N 은 두 클래스 m 과 n 의 데이터 수의 합이고 $x_{m,k}$ 과 $x_{n,k}$ 은 각각 두 클래스의 i_1, j 의 특징신호 값들이다. i_2 는 이렇게 하여 구해진 특징신호로서 상관관계를 고려했을 때 i_1 다음으로 가장 우수한 인덱스를 나타낸다. α

는 FDR과 상관계수 중 어느 것을 중시하는 지 나타내는 가중치로서 이 값이 1이면 상관계수는 무시한 채 i_1 을 제외한 나머지 신호 중에서 가장 높은 FDR을 선택하며, 이 값이 0이면 FDR은 무시하고 i_1 과 상관계수가 가장 낮은 것을 선택하게 된다. 본 연구에서는 0.5를 적용하였다. 이와 같은 방식으로 각 클래스 조합의 분류 성능이 가장 우수한 두개의 특징신호 i_1 과 i_2 가 결정되면 이들을 모두 모아 하나의 그룹을 만들며, 이때 각 조합마다 선정된 두개의 특징신호들은 서로 중복되는 것이 존재할 수 있다. 그 결과 열림과 닫힘에 대해 각각 선정된 특징신호들은 <Table 3>과 같다. 이렇게 선정된 특징신호들은 특징신호 간에 상관관계가 되도록 적으면서 8가지의 클래스를 가장 잘 식별하는 것들을 추린 것이다.

Table 3 Selected feature from each combination

(a) Selected feature group for open operation

Class order(combination)		Class 1&2	Class 1&3	Class 1&4	Class 1&5	Class 1&6	Class 1&7	Class 1&8
Feature ID	i1	3	3	1	2	3	3	1
	i2	13	13	13	1	13	13	13
Class order(combination)		Class 2&3	Class 2&4	Class 2&5	Class 2&6	Class 2&7	Class 2&8	Class 3&4
Feature ID	i1	3	4	10	3	10	10	1
	i2	13	3	4	13	2	2	2
Class order(combination)		Class 3&5	Class 3&6	Class 3&7	Class 3&8	Class 4&5	Class 4&6	Class 4&7
Feature ID	i1	2	2	3	1	2	1	13
	i2	1	1	13	13	10	2	3
Class order(combination)		Class 4&8	Class 5&6	Class 5&7	Class 5&8	Class 6&7	Class 6&8	Class 7&8
Feature ID	i1	1	2	13	13	3	1	3
	i2	13	1	3	3	13	13	13
Single group of features		1, 2, 3, 4, 10, 13						

(b) Selected feature group for close operation

Class order(combination)		Class 1&2	Class 1&3	Class 1&4	Class 1&5	Class 1&6	Class 1&7	Class 1&8
Feature ID	i1	6	10	2	2	2	2	2
	i2	9	9	1	1	1	1	1
Class order(combination)		Class 2&3	Class 2&4	Class 2&5	Class 2&6	Class 2&7	Class 2&8	Class 3&4
Feature ID	i1	6	6	11	6	6	6	1
	i2	1	9	6	11	11	11	2
Class order(combination)		Class 3&5	Class 3&6	Class 3&7	Class 3&8	Class 4&5	Class 4&6	Class 4&7
Feature ID	i1	1	10	1	1	2	2	2
	i2	2	4	2	2	1	1	1
Class order(combination)		Class 4&8	Class 5&6	Class 5&7	Class 5&8	Class 6&7	Class 6&8	Class 7&8
Feature ID	i1	2	2	2	2	1	1	6
	i2	1	1	1	1	2	2	7
Single group of features		1, 2, 4, 6, 7, 9, 10, 11						

3.3 고장분류

분류를 위해 본 연구에서는 가장 대표적 기계학습 알고리즘 중 하나인 K-Nearest Neighbor(KNN) 방법을 사용하였다. KNN 알고리즘은 하나의 test data와 클래스가 식별되어 있는 다수의 training data 사이에 거리를 측정하고, 이 중에서 가장 근접한 K개의 이웃을 구한 후, 현재의 data를 가장 수가 많은 클래스로 추정하는 알고리즘이다. 따라서 KNN 분류 결과는 근접 개수를 나타내는 K값과 거리를 측정하는 방식에 따라 달라지게 되며, 이들을 hyper-parameter 라 한다. 거리 측정 방식은 대표적으로 Euclidean과 Mahalanobis 방식이 있으며 다음과 같은 수식으로 정의된다.

$$d_{\text{Euclidean}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T (\mathbf{x} - \mathbf{y})} \quad (4)$$

$$d_{\text{Mahalanobis}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T \sum_{i=1}^n (\mathbf{x} - \mathbf{y})} \quad (5)$$

여기서 X 와 Y 는 각각 현재의 데이터 점과 training 데이터 점에 대해 앞에서 설명한 방법대로 구한 특징 신호 벡터를 나타내고 \sum 는 training 데이터 전체에 대해 구해진 특징 신호 벡터간의 공분산 행렬을 의미한다.

가장 우수한 분류성능을 나타내는 K값과 거리 측정 방식을 결정하기 위해 본 연구에서는 k-fold 교차검증을 수행하였다(소문자 k는 대문자 K와 다름). 이를 위해 모든 데이터를 training 데이터 7과 test 데이터 3의 비율로 나눈 후 test 데이터는 training을 마친 후 최종 성능평가를 위해 사용되었다. Training 데이터는 다시 k-fold 교차검증을 위해 5개의 fold로 나누었으며 이 중 4개의 fold를 training 세트, 나머지 하나를 validation 세트로 나누었다. 이후 validation 데이터와 training 데이터 간에 KNN을 적용, validation 데이터의 클래스를 추정 또는 예측(prediction)한 후 실제 클래스와 비교하여 분류 정확도(accuracy)를 평가하였으며, 이는 해당 데이터 중 제대로 클래스를 예측한 것의 비율로 정의된다. 이러한 작업을 5개의 fold에 대해 돌아가면서 하나는 validation 나머지 넷은 training으로 하여 KNN 정확도를 구한 후 5개의 결과를 평균하였다.

한편, 앞서 언급한 대로 KNN 분류 성능은 hyper-parameter, 즉 K값과 거리 측정 방식에 따라 달라지는데, 가장 우수한 성능을 구현하는 파라미터를 찾기 위해

Table 4 Accuracies of each hyper-parameters for each door operation

K		3	5	7	9	11
Open	Euclidean	96.4%	94.7%	93.8%	95.3%	95.1%
	Mahalanobis	92.1%	93.7%	92.8%	90.4%	89.5%
Close	Euclidean	91.2%	92.4%	90.4%	90.9%	90.1%
	Mahalanobis	90.7%	91.1%	89.1%	88.3%	89.5%

K값은 3에서 11까지 2씩 증가를, 거리 측정 방식은 Euclidean과 Mahalanobis 두 가지를 시도, 총 10가지의 파라미터 하에서, 각각 k-fold 검증을 통해 평균 정확도를 구한 후 그 값이 가장 우수한 것을 채택하였으며 이를 열림과 닫힘에 대해 적용한 결과, 해당 파라미터는 각각 K값이 3과 5로 나타났으며, 거리측정방식은 둘 다 Euclidean으로 나타났다. 또한 각 파라미터의 조합을 적용한 k-fold 검증에서의 정확도는 <Table 4>와 같이 정리할 수 있다.

이렇게 열림과 닫힘에 대해 얻은 최적 KNN 모델을 test 데이터에 적용하여 분류를 수행한 결과 <Fig. 6>과 같은 혼동행렬을 얻었다. 여기서 output class로 표시된 행은 예측된 클래스를, target class로 표시된 열은 실제 클래스를 나타내며, 대각선 셀 내의 값은 총 187개의 test 데이터 중에 해당 클래스로 예측한 것의 개수를, 그 밑의 %는 해당 클래스의 비율을 뜻한다. 대각선 셀 중 가장 아래에 있는 값은 정확도이며, 각 대각선 셀의 것을 모두 한 것으로 전체 데이터 중에 제대로 예측한 것의 비율을 나타낸다. 열림 닫힘에 대해 정확도를 조사한 결과 각각 95.2%와 89.8%으로 나타났으며, 닫힘이 열림에 비해 분류 결과가 좋지 않았다. 그 이유는 닫힘의 경우 <Fig. 3>과 같이 출입문을 닫기 위해 마지막에 높은 하중을 가하는데 이 때 전류가 크게 튀면서 정확한 분류를 수행하는데 영향을 주는 것으로 보인다. 열림의 경우에는 클래스 4번 ‘하부 이물질’, 6번 ‘베어링 인공 결함’ 및 8번 ‘베어링/롤러 인공 결함’의 분류가 제대로 이루어지지 않았음을 알 수 있으며, 이는 해당 열에서 각각 실제 클래스 대비 오진단인 4회, 2회, 3회 있는 것에서 확인할 수 있다. 닫힘의 경우에는 4번과 7번 ‘롤러 인공 결함’에서 각각 11 및 7회의 큰 오진단이 발견되었으며 이들이 정확도에 영향을 주었다. 이를 종합하면, 대체로 클래스 4, 6, 7, 8번에서 오진단이 확인된 것이며, 이들에 대해 원신호를 비교해 보았더니 4번과 6번, 그리고 7번과 8번 간 신호가 매우 유사

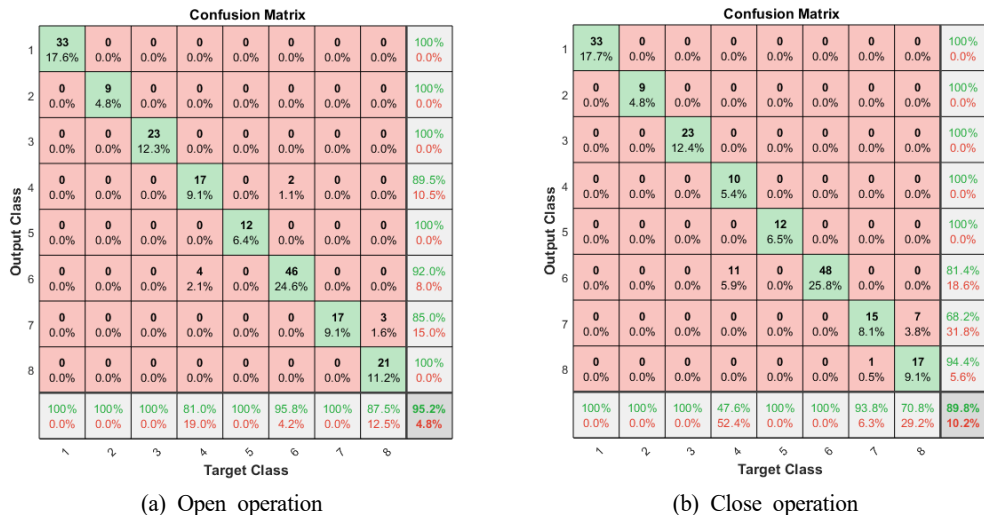


Fig. 6 Confusion matrixes according to door operation

하였고, 이로 인해 오진단이 많았던 것으로 판단된다. 한편 이들의 분류결과를 다른 각도에서 보면, 각 고장 모드는 해당 열에서 맨 위 행에 해당하는 정상으로 오진단하지 않는 것을 볼 때 다른 고장모드의 식별은 몰라도 적어도 정상과의 구분은 잘하고 있다.

4. 결 론

본 연구에서는 전동차 출입문의 고장을 진단하여 현재 상태에 대한 정확한 판단과 이를 통한 효율적인 정비를 위해 모터 전류를 활용하여 data-driven 방법을 제안하였다. 이를 위해 출입문에 있어서 가혹한 조건으로서 고장으로 판단될 여지가 있는 상태와 실제로 내부 부품의 마모 등과 같은 고장이 발생한 상태로 구분 지어 실험을 진행하였다. 각각의 고장 모드로부터 얻어지는 모터의 전류 신호를 확보하고 열림과 닫힘에 대해 구분한 후 다양한 특징신호를 계산하여 분류에 사용하였다. 그 결과, 정상과 비교하여 다른 상태에 대한 진단은 완벽하게 하는 것을 확인할 수 있었다. 따라서 본 연구 결과를 통해 출입문의 상태에 기반한 정비를 진행할 때 정상의 상태를 정의하고 다른 고장모드와 비교가 가능함을 확인할 수 있었다. 하지만 실제로는 고장이 아닌 상태인 ‘하부 레일 이물질’ 상태가 내부의 부품에 마모가 발생한 ‘캠팔로워 베어링 인공 마모’와 완벽하게 분리되지 않는 것을 확인하였다. 또한 ‘캠팔로워 베어링 인공 마모’와 ‘롤러/캠팔

로워 베어링 인공 마모’가 완벽하게 분리되지 않는 것을 확인하였으며 이는 닫힘에 경우 두드러졌다. 본 연구 결과를 통해 출입문에 있어서 캠팔로워 베어링에 마모가 발생했을 경우는 정상과는 구분할 수 있지만 다른 상태와의 비교는 어려운 경우가 있었으며 또한 다른 고장 모드와 혼재되어 발생했을 경우 캠팔로워 베어링 마모의 영향은 미미함을 확인할 수 있었다. 이에 대한 정확한 분류를 위해서 차후 출입문의 열림과 닫힘의 모터 전류 프로파일을 서로 다른 속도 구간으로 나누어 연구를 진행할 계획이다. 또한 특징신호를 계산하지 않고 원신호를 입력으로 하는 deep learning 방법을 적용하여 얻은 결과와 특징신호를 계산한 방법론의 결과를 비교할 계획이다.

References

- [1] Bai, H. (2010). “A generic fault detection and diagnosis approach for pneumatic and electric driven railway assets”. Doctoral Dissertation, University of Birmingham.
- [2] Ham, S. J., and Choi, J. H. (2019). “Diagnosis of railway component based on motor current signal”. The Korean Society of Mechanical Engineers Reliability Engineering Division 2019 Spring Conference, p. 28.
- [3] Turgis, F., Copin, R., Loslever, P., Cauffriez, L., and Caouder, N. (2009). “Design of a testing bench for simulating tightened-up operating conditions of train’s pas-

- senger access". In Proc. European Safety and Reliability Conference (ESREL), pp. 21-23.
- [4] Cauffriez, L., Loslever, P., Caouder, N., Turgis, F., and Copin, R. (2013). "Robustness study and reliability growth based on exploratory design of experiments and statistical analysis : a case study using a train door test bench". The International Journal of Advanced Manufacturing Technology, Vol. 66, No. 1-4, pp. 27-44.
- [5] Shuai, L., Limin, J., Yong, Q., Bo, Y., and Yanhui, W. (2014). "Research on urban rail train passenger door system fault diagnosis using PCA and rough set". Open Mechanical Engineering Journal, Vol. 8, pp. 340-348.
- [6] Cauffriez, L., Grondel, S., Loslever, P., and Aubrun, C. (2016). "Bond graph modeling for fault detection and isolation of a train door mechatronic system". Control Engineering Practice, Vol. 49, pp. 212-224.
- [7] Sun, Y., Xie, G., Cao, Y., and Wen, T. (2019). "Strategy for fault diagnosis on train plug doors using audio sensors". Sensors, Vol. 19, No. 1, pp. 1-18.
- [8] Yan, J., and Lee, J. (2005). "Degradation assessment and fault modes classification using logistic regression". Journal of manufacturing Science and Engineering. Vol. 127, No. 4, pp. 912-914.
- [9] Alessi, A., La-Cascia, P., Lamoureux, B., Pagnaloni, M., and Dersin, P. (2016). "Health assessment of railway turnouts : a case study". In I: Euroean Conference of the Prognostics and health management society, Vol. 7.
- [10] Lee, J. *et al.* (2016). Fault detection and diagnosis of railway point machines by sound analysis. Sensors, Vol. 16, No. 4, p. 549.
- [11] Han, Y. *et al.* (2013). "Online predictive diagnosis of electrical train door systems". In Proc.10th World Congress of Railway Research (WCRR).
- [12] Bishop, C. M. (2006). "Pattern recognition and machine learning". springer.